

Машинное обучение

Семинар 13

Понижение размерности и метод главных КОМПОНЕНТ

В машинном обучении часто возникает задача уменьшения размерности признакового пространства. Для этого можно, например, удалять признаки, которые слабо коррелируют с целевой переменной; выбрасывать признаки по одному и проверять качество модели на тестовой выборке; перебирать случайные подмножества признаков в поисках лучших наборов.

Ещё одним из подходов к решению задачи является поиск новых признаков, каждый из которых является линейной комбинацией исходных признаков. В случае использования квадратичной функции ошибки при поиске такого приближения получается *метод главных компонент* (principal component analysis, PCA), о котором и пойдет речь.

Существует несколько разных постановок метода главных компонент. Мы разберём некоторые из них.

1 Максимизация дисперсии

Задача 1.1. Рассмотрим многомерную случайную величину $(X_1, \dots, X_D)$. Пусть у неё нулевое математическое ожидание. Мы собрали для такой случайной величины ℓ наблюдений и записали их в виде матрицы $X \in \mathbb{R}^{\ell \times D}$. Найдите выборочную ковариационную матрицу для выборки X .

Решение. Нам надо найти ковариационную матрицу между столбцами матрицы X . На её диагонали будут стоять дисперсии. Обычно $Var(X_j) = \mathbb{E}(X_j^2) - \mathbb{E}^2(X_j)$. Так как математическое ожидание каждого столбца равно нулю, тогда $Var(X_j) = \mathbb{E}(X_j^2)$, и оценку таких дисперсий можно найти по формуле

$$\hat{\sigma}_j^2 = \frac{1}{\ell} \sum_{i=1}^{\ell} x_{ij}^2.$$

В остальных клетках матрицы будут стоять выборочные ковариации. Обычно $cov(X_j, X_k) = \mathbb{E}(X_j X_k) - \mathbb{E}(X_j)\mathbb{E}(X_k)$. Так как математическое ожидание каждого столбца равно нулю, тогда $cov(X_j, X_k) = \mathbb{E}(X_j X_k)$, и их оценки можно найти по формуле

$$\hat{\rho}_{jk} = \frac{1}{\ell} \sum_{i=1}^{\ell} x_{ij} \cdot x_{ik}.$$

Получается, что выборочную ковариационную матрицу можно записать как $\frac{X^T X}{\ell}$. В вычислениях ниже нам будет часто встречаться матрица $X^T X$. Будем держать в голове, что она пропорциональна выборочной ковариационной матрице. Отметим, что если бы математическое ожидание было бы неизвестно, для получения несмещённой оценки дисперсии и ковариации мы должны были бы делить на $\ell - 1$. ■

Пусть $X \in \mathbb{R}^{\ell \times D}$ — матрица «объекты-признаки», где ℓ — число объектов, а D — число признаков. Будем считать, что данные являются центрированными — то есть среднее в каждом столбце матрицы X равно нулю. Мы хотим уменьшить размерность пространства до d . При этом каждый новый признак будет линейно выражаться через исходные с какими-то весами

$$z_{ij} = \sum_{k=1}^D x_{ik} u_{kj}.$$

Чем больше дисперсии выборки мы сохранили, тем больше сохраняется информации. Будем искать веса $u_1, \dots, u_D \in \mathbb{R}^D$ так, чтобы сохранить максимальную дисперсию:

1. $z_1 = Xu_1$: выборочная дисперсия z_1 должна быть максимальной при условии $\|u_1\|^2 = 1$.
2. $z_2 = Xu_2$: выборочная дисперсия z_2 должна быть максимальной при условии $\|u_2\|^2 = 1$ и $u_1 \perp u_2$.
3. $z_3 = Xu_3$: выборочная дисперсия z_3 должна быть максимальной при условии $\|u_3\|^2 = 1$ и $u_1 \perp u_3, u_2 \perp u_3$
4. и так далее

В матричном виде мы можем записать это как $Z = XU$. При этом матрица U будет ортогональной, то есть $U^T U = I$. Нам это нужно, чтобы задача оптимизации имела единственное решение.

Давайте попробуем найти первую главную компоненту. Сведём все требования к ней в оптимизационную задачу. Данные нормированы. Преобразование предполагает, что мы взвесим исходные случайные величины с какими-то весами. Получается, что математическое ожидание по-прежнему будет нулевым, и выборочная дисперсия будет совпадать со вторым моментом

$$\begin{cases} \|Xu_1\|^2 = u_1^T X^T X u_1 \rightarrow \max_{u_1} \\ \|u_1\|^2 = u_1^T u_1 = 1. \end{cases}$$

Запишем лагранжиан (знак минус перед λ используется для удобства):

$$L(u_1, \lambda) = u_1^T X^T X u_1 - \lambda(u_1^T u_1 - 1).$$

Продифференцируем его и приравняем нулю:

$$\frac{\partial L}{\partial u_1} = 2X^T X u_1 - 2\lambda u_1 = 0.$$

Получается, что

$$X^T X u_1 = \lambda u_1$$

Отсюда получаем, что u_1 должен быть собственным вектором матрицы $X^T X$. Учтём это и преобразуем функционал:

$$\|X u_1\|^2 = u_1^T X^T X u_1 = \lambda u_1^T u_1 = \lambda \rightarrow \max_{u_1}$$

Значит, собственный вектор u_1 должен соответствовать максимальному собственному значению матрицы $X^T X$. Напомним, что эта матрица пропорциональна ковариационной матрице. То есть именно она характеризует дисперсию выборки.

Для следующих компонент к оптимизационной задаче будут добавляться требования ортогональности предыдущим компонентам. Решая эти задачи, мы получим, что главная компонента u_i равна собственному вектору, соответствующему i -му собственному значению.

После того, как найдены главные компоненты, можно проецировать на них и новые данные. Если нам нужно работать с тестовой выборкой X' , то её проекции вычисляются как $Z' = X' U_d$.

Задача 1.2. Давайте убедимся, что мы поняли метод главных компонент и попробуем ответить на следующие вопросы:

1. Чему будет равно среднее z_1 , если исходные данные центрированы? А z_2 ?
2. Докажите, что из того, что $u_1 \perp u_2$ следует, что $z_1 \perp z_2$. Чему будет равна $cov(z_1, z_2)$?
3. Докажите, что $Var(x_1) + \dots + Var(x_D) = Var(z_1) + \dots + Var(z_D)$
4. Выразите $\sum_{k=1}^D \|z_k\|^2$ через собственные числа. Как с помощью собственных чисел оценить долю объяснённой компонентами дисперсии?

Решение.

1. Все исходные переменные центрированы, их математическое ожидание равно нулю. Мы взвешиваем случайные величины с какими-то весами. Математическое ожидание от этого никак не меняется. Оно остаётся нулевым.
2. Из ортогональности u_1 и u_2 следует ортогональность z_1 и z_2

$$z_1^T z_2 = u_1^T X^T X u_2 = \lambda_2 \cdot u_1^T u_2 = 0.$$

Тут мы воспользовались тем, что u_2 это собственный вектор матрицы $X^T X$. Выходит, что

$$cov(z_j, z_k) = \mathbb{E}(z_j \cdot z_k) - \mathbb{E}(z_j) \cdot \mathbb{E}(z_k) = \mathbb{E}(z_j \cdot z_k) = z_j^T z_k = 0.$$

3. С одной стороны

$$\text{Var}(x_1) + \dots + \text{Var}(x_D) = \frac{1}{\ell - 1} \text{tr}(X^T X),$$

так как все дисперсии в ковариационной матрице находятся на диагонали, а след представляет из себя сумму диагональных элементов.

С другой стороны

$$\text{Var}(z_1) + \dots + \text{Var}(z_D) = \frac{1}{\ell - 1} \text{tr}(Z^T Z) = \frac{1}{\ell - 1} \text{tr}(U^T X^T X U) = \frac{1}{\ell - 1} \text{tr}(X^T X),$$

так как $U^T U = I$, под следом матрицы можно переставлять по циклу и, снова, все дисперсии находятся в матрице $Z^T Z$ на диагонали. Обратите внимание, что все недиагональные элементы в $Z^T Z$ будут нулевыми. Мы доказали это в предыдущем пункте.

4. Так как все математические ожидания нулевые, $\|z_k\|^2 = z_k^T z_k = \text{Var}(z_k)$. Выходит, что $\sum_{k=1}^D \|z_k\|^2 = \sum_{k=1}^D \text{Var}(z_k) = \sum_{k=1}^D \text{Var}(x_k)$. Выразим эту сумму через собственные значения

$$\sum_{k=1}^D \|z_k\|^2 = \sum_{k=1}^D \|X u_k\|^2 = \sum_{k=1}^D u_k^T X^T X u_k = \sum_{k=1}^D u_k^T \lambda_k u_k = \sum_{k=1}^D \lambda_k.$$

Выходит, что если мы оставляем в данных d компонент, то дробь $\frac{\lambda_1 + \dots + \lambda_d}{\lambda_1 + \dots + \lambda_D}$ показывает, какая доля дисперсии сохранилась после проецирования выборки на главные компоненты.

■

Задача 1.3. Фил придумал метод бесполезных компонент. Как и в методе главных компонент, бесполезные компоненты являются линейными комбинациями исходных переменных. Бесполезные компоненты также ортогональны между собой. Вектор весов, с которыми исходные переменные входят в бесполезную компоненту, всегда имеет единичную длину. В отличие от метода главных компонент, первая бесполезная компонента обладает наименьшей выборочной дисперсией. Вторая бесполезная компонента ортогональна первой и обладает наименьшей выборочной дисперсией при условии ортогональности. И так далее.

Как связаны метод бесполезных компонент и метод главных компонент?

Решение. Компоненты из метода бесполезных компонент — это ровно главные компоненты, но только перечисленные в обратном порядке.

■

2 Минимизация ошибки приближения

Пусть $X \in \mathbb{R}^{\ell \times D}$ — матрица «объекты-признаки», где ℓ — число объектов, а D — число признаков. Поставим задачу уменьшить размерность пространства до d . Будем считать, что данные являются центрированными — то есть среднее в каждом столбце матрицы X равно нулю.

Мы хотим, чтобы каждый новый признак линейно выражался через исходные

$$z_{ij} = \sum_{k=1}^D x_{ik} u_{kj}.$$

В матричном виде это можно записать как

$$Z = XU^T.$$

Чтобы у этого уравнения существовало единственное решение, нужно ввести на матрицу весов ограничения. Пусть она будет ортогональной $U^T U = I$. Если это требование выполнено, можно получить формулу для матрицы X

$$X = ZU.$$

В матрице Z будет меньше признаков, чем в X , так как $d < D$. Это равенство нельзя выполнить строго. Нам придётся потребовать, чтобы отклонение матрицы признаков X от ZU было как можно меньше. Размер этого отклонения будем вычислять с помощью нормы Фробениуса:

$$\begin{cases} \|X - ZU\|_F \rightarrow \min_{Z,U} \\ U^T U = I \end{cases}$$

Норма Фробениуса матрицы — это сумма квадратов ее значений. Получившаяся задача — это задача матричного разложения. Необходимо представить матрицу X в виде произведения двух матриц U и W , которые будут иметь меньший ранг. То есть нужно уменьшить ранг матрицы, при этом потеряв как можно меньше информации в ней.

Решением данной задачи также являются собственные векторы ковариационной матрицы.

3 Задачи на метод главных компонент

1

Задача 3.1. У бесстрашного исследователя Ильдуса есть набор точек $(x_1, y_1), \dots, (x_n, y_n)$. Ильдус находит прямую, сумма расстояний от которой до каждой точки минимальна. Верно ли, что прямая проходит через точку $(\bar{x}, \bar{y})$?

¹Задачи взяты из коллекции Бориса Демешева: https://github.com/bdemeshev/mlearn_pro

Решение. Да. Например, прямую можно задать вектором w единичной длины и числом b , $w^T \begin{pmatrix} x \\ y \end{pmatrix} = b$. Обозначим вектор $(x_i, y_i)^T$ буквой v_i . Тогда нам нужно минимизировать функцию

$$\sum (w^T v_i - b)^2.$$

Дифференцируем по b и получаем $\sum w^T v_i = n \cdot b$, что и означает, что прямая проходит через среднюю точку,

$$w^T \begin{pmatrix} \bar{x} \\ \bar{y} \end{pmatrix} = b.$$

■

Задача 3.2. Есть две переменных, $x_1 = (1, 0, 0, 3)^T$, $x_2 = (3, 2, 0, 3)^T$. Найдите первую и вторую главные компоненты.

Решение. Матрица с центрированными столбцами имеет вид: $\tilde{X} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \\ -1 & -2 \\ 2 & 1 \end{pmatrix}$

Тогда $\tilde{X}^T \tilde{X} = \begin{pmatrix} 6 & 4 \\ 4 & 6 \end{pmatrix}$.

Её собственные числа: $\lambda_1 = 10$, $\lambda_2 = 2$, собственные вектора $u_1 = (1/\sqrt{2} \ 1/\sqrt{2})^T$, $u_2 = (1/\sqrt{2} \ -1/\sqrt{2})^T$. Найдём главные компоненты:

$$Z = XU = \begin{pmatrix} 0 & 1 \\ -1 & 0 \\ -1 & -2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ -1/\sqrt{2} & -1/\sqrt{2} \\ -3/\sqrt{2} & 1/\sqrt{2} \\ 3/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

Первая и вторая главные компоненты — это первый и второй столбцы матрицы Z соответственно.

■

4 Нейросетевые методы

Задачу понижения размерности можно решать и нейросетевыми методами. Один из таких подходов называется автоэнкодер. Две основные компоненты автоэнкодера это энкодер (encoder) и декодер (decoder), где энкодер из исходных данных получает так называемое латентное представление данных, а декодер из латентных данных восстанавливает исходные. Схема Автоэнкодера изображена на рисунке ниже

1 Обозначим энкодер за $E : \mathbb{R}^D \rightarrow \mathbb{R}^d$, а декодер за $D : \mathbb{R}^d \rightarrow \mathbb{R}^D$. Более формально:

$$x' = D(E(x)), \text{ где } x', x \in \mathbb{R}^D, y = E(x) \in \mathbb{R}^d.$$

Обычно $d < D$ но есть исключения например Sparse Auto Encoders (SAE), где $D > d$, но об этом на следующем семинаре.




Рис. 1. Схема автоэнкодера

Теперь перейдем к обучению автоэнкодера. Для обучения модели на требуется ввести лосс реконструкции. В простейшем виде он равен:

$$L = \|x - x'\|_2^2,$$

где лосс тем меньше, чем ближе реконструированный вход к исходному входу. Как видно для обучения данной модели не требуется разметка данных. В итоге Автоэнкодер позволяет сжать представления данных с размерности D до размерности d - размерности латентного представления.

Важной разновидностью автоэнкодера является Denoising Autoencoder (DAE), который позволяет расшумлять данные а также получать качественные латентные представления для шумных данных. Покажем как его обучать. Пусть x входные данные, а $N(\mu, \sigma)$ - нормальный шум. Тогда обучение модели производится путем минимизации лосса $L = \|x' - x\|_2^2$, где

$$x' = D(E(x + \epsilon N(\mu, \sigma))), \text{ и } y = E(x + \epsilon N(\mu, \sigma)).$$

Подобным образом можно сживать не только вектора но и матрицы и тензора, например, изображения. В случае векторов, энкодер и декодер обычно являются несколькими Dense слоями, в то время как для изображений часто используются энкодер и декодер на основе сверточных слоев. В декодере при этом используется процедура обратная свертке.

Задача Дано изображение 128×128 . Какой будет размер представления изображения мсле применения 3 сверток 5×5 в энкодере с паддингом 1 и страйдом 2?

Решение Воспользуемся формулой для размеравыхода свертки:

$$d_{out} = \left\lceil \frac{d_{in} + 2p - k}{s} \right\rceil + 1,$$

где d_{in} и d_{out} входная и выходная размерности изображений, p – паддинг, k – размер свертки, s – страйд свертки. Квадратными скобками обозначено округление вниз. Трижды применим эту формулу к входным данным и подставим значения $k = 5$, $s = 2$, $p = 1$:

1) При первом применении $d_{out} = 63$ 2) При втором применении $d_{out} = 31$ 3) При третьем применении $d_{out} = 15$.

Ответ: 15.